

Question and Answer BLDS

Bối cảnh:

- | | |
|--|------------------|
| → Bộ luật Dân sự 2015 (BLDS2015) gồm 689 Điều, 36 Chương | Train : 2496 mẫu |
| → Xây dựng hệ thống QA tự động cho BLDS2015 | Valid : 534 mẫu |
| → Trả lời câu hỏi tiếng Việt + trích dẫn đúng số Điều làm căn cứ | Test : 536 mẫu |
| → So sánh hiệu quả của RAG và Fine-tuning (riêng lẻ & kết hợp) | Total : 3566 mẫu |

Công nghệ cốt lõi:

- RAG – Truy xuất điều khoản liên quan theo thời gian thực
- QLoRA – Fine-tune mô hình 3B tham số với chi phí GPU thấp
- Qwen2.5-3B – Mô hình ngôn ngữ nền tảng (Alibaba Cloud)

=== QUESTION (USER PROMPT) ===

Nếu bên cho thuê không thực hiện đúng nghĩa vụ liên quan đến hành vi lạm dụng quyền dân sự, hậu quả là gì?

=== ANSWER FOR FINE-TUNING (ASSISTANT RESPONSE) ===

Trường hợp cá nhân, pháp nhân không tuân thủ quy định tại khoản 1 Điều này thì Tòa án hoặc cơ quan có thẩm quyền khác căn cứ vào tính chất, hậu quả của hành vi vi phạm mà có thể không bảo vệ một phần hoặc toàn bộ quyền của họ, buộc bồi thường nếu gây thiệt hại và có thể áp dụng chế tài khác do luật quy định. Việc bảo vệ quyền dân sự theo thủ tục hành chính được thực hiện trong trường hợp luật quy định.

Question and Answer BLDS

Chunking

711 chunks theo Điều luật · Metadata phân cấp 4 tầng · Verbatim

Embedding

vietnamese-sbert / multilingual-e5-large · L2-normalize · FAISS
IndexFlatIP

Retrieval

BM25 + Dense Hybrid · MemPalace Scoping giảm 85% search space

Reranking

BGE-Reranker-V2-M3 · Bi-encoder (top-20) → Cross-encoder (top-5)

LLM

Qwen2.5-3B · GQA · SwiGLU · RoPE · RMSNorm · ChatML

Fine-tuning

QLoRA: NF4 4-bit · LoRA rank · Completion-only loss · Cosine LR


Evaluation

BLEU-4 · ROUGE-L · BERTScore (quan trọng nhất với tiếng Việt — nhạy với dấu thanh)


Question and Answer BLDS

Phân tích Dữ liệu - Bộ Luật Dân Sự 2015

Phân phối độ dài chunk



Số Điều theo Chương



Question and Answer BLDS

RAG (Retrieval-Augmented Generation):

- Kết hợp truy xuất thông tin + sinh ngôn ngữ từ LLM
- Giải quyết hallucination & kiến thức lỗi thời


Pipeline 6 giai đoạn:

1. QUERY – Tiếp nhận câu hỏi tiếng Việt
2. SCOPE – Phân loại, thu hẹp xuống Chương liên quan
3. RETRIEVE – BM25 / Vector Search → Top-k điều khoản
4. CONTEXT – Định dạng ngữ cảnh pháp lý
5. LLM – Qwen2.5-3B + LoRA sinh câu trả lời
6. ANSWER – Trả lời kèm trích dẫn số Điều

Question and Answer BLDS

Tổng Quan Kiến Trúc Hệ Thống

Pipeline 6 giai đoạn tuần tự (BLDS2015-RAG-QA):



RAG kết hợp truy xuất thông tin (Retrieval) với sinh ngôn ngữ (Generation) — bổ sung kiến thức pháp lý thực tế mà LLM không có trong training data.

4 cấu hình thực nghiệm: Base | Base+RAG | Fine-tuned | Fine-tuned+RAG

Question and Answer BLDS

Chiến Lược Chunking Văn Bản Pháp Lý

Nguyên lý Chunking

- Mỗi chunk = 1 đơn vị ngữ nghĩa độc lập
- Đơn vị tự nhiên trong BLDS 2015: Điều luật
- Không tham chiếu sang chunk khác mới hiểu được
- Verbatim storage — giữ nguyên văn gốc

Nguyên tắc cốt lõi:

Tính chính xác từng chữ của điều khoản pháp lý là bắt buộc — paraphrase có thể thay đổi nghĩa pháp lý.

Tổng chunks

711 chunks
từ 689 Điều

Token TB

~120 tokens
/ chunk

Cấu trúc

4 tầng: Phần
→ Chương → Mục → Điều

Metadata

Dùng cho Scoping
& trích dẫn pháp lý

Phần

Chương

Mục

Điều (Chunk)

Question and Answer BLDS

Mô Hình Embedding — Biểu Diễn Ngữ Nghĩa

Sentence Transformers (SBERT)

- Biến đổi BERT → encoder tạo sentence embeddings
- Siamese Networks: 2 BERT xử lý song song
- Mean Pooling → fixed-size sentence vector
- Cosine Similarity để so sánh câu trực tiếp

```
u = MeanPool(BERT(s1))    v =  
MeanPool(BERT(s2))  
similarity(u, v) = cos(u,v) = (u·v) / (||u||  
· ||v||)
```

Mô hình được sử dụng

multilingual-e5-large

Microsoft · 93 ngôn ngữ · 24 transformer layers ·
contrastive learning

vietnamese-sbert

keepitreal · Fine-tuned từ XLM-RoBERTa · Tối ưu tiếng
Việt

Question and Answer BLDS

FAISS Vector Store — Tìm Kiếm Nearest Neighbor

FAISS (Facebook AI Similarity Search) — thư viện tìm kiếm vector tối ưu hóa cao trong không gian chiều cao.

IndexFlatIP — Exact Inner Product Search

- Lưu toàn bộ vector trong bộ nhớ, brute-force search
- IP = Inner Product → với L2-normalized vectors = cosine similarity
- Trả về k chunks có inner product lớn nhất

$$\text{score}(q, d) = q \cdot d = \sum_i q_i \cdot d_i \quad (\text{với } ||q|| = ||d|| = 1)$$

Lợi ích: giảm ~85% không gian tìm kiếm (711 → 50–100 chunks) — tăng precision & tốc độ

Kiến Trúc Multi-Index (2 tầng)

Global Index

711 vectors
Fallback khi scoped
search thiếu kết quả

Per-Chapter Index

1 sub-index / Chương
Scoped search trong
phạm vi 3 Chương

Question and Answer BLDS

BM25 — Sparse Retrieval & Hybrid Search

BM25 (Best Match 25) — thuật toán ranking dựa trên TF-IDF, state-of-the-art trong sparse retrieval nhiều thập kỷ.

$$\text{BM25}(d, q) = \sum_i \text{IDF}(t_i) \cdot (f(t_i, d) \cdot (k_1 + 1)) / (f(t_i, d) + k_1 \cdot (1 - b + b \cdot |d| / \text{avgdl}))$$

Tham số:

$f(t_i, d)$ Tần suất term t_i trong document d

$k_1 = 1.2-2.0$ Kiểm soát TF saturation

$b = 0.75$ Kiểm soát length normalization

$\text{IDF}(t_i)$ Phạt term xuất hiện quá nhiều docs

Hybrid Retrieval

- Kết hợp BM25 (sparse) + Dense Vector (semantic)
- BM25 tốt với từ khóa chính xác (số Điều, tên luật)
- Dense Vector tốt với paraphrase và ngữ nghĩa

$$\text{score} = \alpha \cdot \text{score_dense} + (1 - \alpha) \cdot \text{score_BM25}$$

Question and Answer BLDS

MemPalace Metadata Scoping

Kỹ thuật thu hẹp không gian tìm kiếm trước vector search — lấy cảm hứng từ kỹ thuật trí nhớ Memory Palace (Method of Loci).

Keyword Matching

- Mỗi Chương có tập từ khóa domain đặc trưng
- Ví dụ Ch.16 (Hợp đồng): "hợp đồng", "ký kết", "vi phạm"
- Từ ghép nhiều từ → domain-specific → điểm cao hơn

Semantic Similarity

- Mỗi Chương có embedding của tên Chương
- Tính cosine similarity giữa query và tên Chương
- Trọng số $\times 2.0$ — khả năng khái quát hóa tốt hơn keyword

$$\text{score_kw}(c, q) = \sum (1 + \text{len}(\text{kw.split()})) \times 0.1$$

$$\text{score_total} = \text{score_kw} + 2.0 \times \text{score_sem}$$

Kết quả: Giảm từ 711 xuống 50–150 chunks (>85%) → Top-3 Chương được chọn → Tăng Precision & Tốc Độ

Question and Answer BLDS

MemPalace Metadata Scoping

Mỗi Chương được gán một tập từ khóa đặc trưng (domain keywords). Ví dụ:

- Chương 16 (Hợp đồng): ["hợp đồng", "ký kết", "vi phạm", "bồi thường", ...]
- Chương 20 (Thừa kế): ["thừa kế", "di chúc", "di sản", "người thừa kế"]
- Chương 3 (Cá nhân): ["cá nhân", "năng lực", "hành vi", "mất tích"]

Điểm keyword cho Chương c:

$$\text{score_kw}(c, q) = \sum_{\{kw \in \text{DOMAIN_KEYWORDS}[c] \cap q\}} (1.0 + \text{len}(kw.\text{split}()) \times 0.1)$$

Trọng số tỷ lệ với số từ trong keyword (từ ghép nhiều từ → domain-specific hơn → điểm cao hơn).

Question and Answer BLDS

Cross-Encoder Reranking

Bi-Encoder (SBERT)

- Encode query & document độc lập nhau
- Nhanh — phù hợp tìm kiếm tập lớn
- Mất thông tin tương tác query-document
- Dùng trong Giai đoạn 1: lấy top-20

Cross-Encoder

- Concat [query; document] → xử lý chung
- Chậm hơn nhưng chính xác hơn nhiều
- Học tương tác sâu giữa query và document
- Dùng trong Giai đoạn 2: rerank top-5

BGE-Reranker-V2-M3 (BAAI)

State-of-the-art multilingual reranker · Huấn luyện bằng LLM-based reward + hard negative mining · Giai đoạn 1: fetch_k=20 → Giai đoạn 2: rerank → top_k=5

Question and Answer BLDS

Qwen2.5-3B-Instruct — Kiến Trúc Decoder-only Transformer

Alibaba Cloud · GPT-style Decoder-only · 3B parameters · Instruction-following

GQA (Grouped Query Attention)

16 query heads, 8 KV heads → giảm 50% KV cache memory. Trung gian giữa MHA và MQA.

SwiGLU Activation

$\text{SwiGLU}(x) = \text{SiLU}(W_1x) \otimes W_2x$ — Gating mechanism linh hoạt hơn ReLU. Dùng trong LLaMA và các LLM hiện đại.

RoPE (Rotary Position Embedding)

Encode vị trí token vào attention computation. Tự nhiên generalize ra context dài hơn training.

RMSNorm

Normalize theo root mean square, bỏ mean centering. Nhanh hơn ~40% so với LayerNorm, kết quả tương đương.

ChatML Format: </im_start/>system / user / assistant</im_end/> — Token đặc biệt phân tách rõ ranh giới các turn và role trong hội thoại.

Question and Answer BLDS

QLoRA — Fine-tuning Hiệu Quả Bộ Nhớ

QLoRA = Quantization + LoRA → Fine-tune mô hình 3B params trên GPU tiêu dùng (3B × 4B = ~12GB nếu FP32).

Quantization (Giảm Độ Chính Xác)

- NF4 (NormalFloat 4-bit): 4-bit → 16 levels, tối ưu phân phối chuẩn của trọng số
- Double Quantization: quantize thêm cả quantization constants (~0.37 bit/param tiết kiệm)
- Bfloat16 Compute: dequantize tạm lên bf16 khi forward/backward, gradient vào LoRA adapters

LoRA — Low-Rank Adaptation

- $\Delta W = B \times A$ ($r \ll \min(d,k)$) — chỉ học ma trận rank thấp
- Giả thiết: sự thay đổi trọng số khi FT có rank thấp
- A khởi tạo $N(0, \sigma^2)$, $B=0 \rightarrow \Delta W=0$ lúc đầu training

$$h = W_0 x + (\alpha/r) \cdot B A x$$

Kỹ thuật Training

DataCollator for Completion Only Loss chỉ tính trên phần assistant response

Cosine LR + Warmup 5% Tránh gradient exploding ở bước đầu

Gradient Accumulation (steps=8)

Effective batch = 8 × micro-batch, tiết kiệm GPU

Paged AdamW 8-bit

Optimizer states 8-bit + paging GPU→CPU, giảm 75%

Question and Answer BLDS

Prompt Engineering & Đánh Giá Định Lượng

Cấu trúc RAG Prompt (3 phần):

```
[NGŨ CẢNH PHÁP LÝ]
{context} ← Top-k chunks + citation

[CÂU HỎI]
{question} ← Câu hỏi tiếng Việt

[YÊU CẦU TRẢ LỜI]
Trả lời + trích dẫn số điều pháp lý
```

Distribution Matching: System prompt inference PHẢI khớp hoàn toàn với system prompt lúc tạo dataset fine-tuning — tránh distribution shift.

Chỉ Số Đánh Giá Định Lượng:

BLEU-4

N-gram precision (1→4-gram)
Brevity Penalty cho câu ngắn

ROUGE-L

Longest Common Subsequence
Chấp nhận paraphrase & thứ tự khác


BERTScore

Contextual embeddings — quan trọng nhất cho tiếng Việt
(BLEU/ROUGE nhạy với dấu thanh)

Fine-tuned + RAG > Fine-tuned > Base+RAG > Base — RAG và Fine-tuning đóng góp bổ sung, không thay thế nhau

Question and Answer BLDS


Training & Validation Loss - Qwen2.5-3B-Instruct QLoRA




Question and Answer BLDS

So Sánh 4 Cấu Hình - Hệ Thống Hỏi Đáp Bộ Luật Dân Sự 2015


BLEU-4




ROUGE-L



BERTScore-F1



Latency(s)



A: Base No RAG B: Base + RAG C: Fine-tuned No RAG D: Fine-tuned + RAG