

**TỔNG LIÊN ĐOÀN LAO ĐỘNG VIỆT NAM
TRƯỜNG ĐẠI HỌC TÔN ĐỨC THẮNG
KHOA CÔNG NGHỆ THÔNG TIN**



**ĐÀO MINH KHÔI – 522H0007
HÀ HUY TÍN – 523H0184
BÙI QUANG VINH – 523H0193**

HỆ THỐNG HỎI ĐÁP THÔNG MINH BỘ LUẬT DÂN SỰ 2015

BÁO CÁO CUỐI KỲ NHẬP MÔN XỬ LÝ NGÔN NGỮ TỰ NHIÊN

THÀNH PHỐ HỒ CHÍ MINH, NĂM 2026

**TỔNG LIÊN ĐOÀN LAO ĐỘNG VIỆT NAM
TRƯỜNG ĐẠI HỌC TÔN ĐỨC THẮNG
KHOA CÔNG NGHỆ THÔNG TIN**



**ĐÀO MINH KHÔI – 522H0007
HÀ HUY TÍN – 523H0184
BÙI QUANG VINH – 523H0193**

HỆ THỐNG HỎI ĐÁP PHÁP LUẬT LUẬT DÂN SỰ 2015

BÁO CÁO CUỐI KỲ NHẬP MÔN XỬ LÝ NGÔN NGỮ TỰ NHIÊN

Người hướng dẫn
Pgs. Ts. Lê Anh Cường

THÀNH PHỐ HỒ CHÍ MINH, NĂM 2026

LỜI CẢM ƠN

Chúng em xin chân thành cảm ơn giảng thầy Lê Anh Cường và Khoa Công nghệ Thông tin, Trường Đại học Tôn Đức Thắng đã tạo điều kiện để thực hiện đề tài. Báo cáo này tổng hợp quá trình xây dựng hệ thống hỏi đáp pháp luật tự động cho Bộ luật Dân sự 2015, bao gồm khâu chuẩn bị dữ liệu, thiết kế truy xuất RAG, fine-tuning mô hình Qwen2.5-3B-Instruct bằng QLoRA, triển khai suy luận và đánh giá định lượng. Trong quá trình thực hiện, nhóm đã kế thừa template báo cáo được cung cấp, đồng thời tổng hợp kết quả từ notebook thực nghiệm, slide trình bày và các hình ảnh kết quả đã có.

Do giới hạn thời gian và tài nguyên GPU, hệ thống vẫn còn một số hạn chế về độ bao phủ dữ liệu, đánh giá theo từng nhóm câu hỏi và tối ưu độ trễ. Tuy nhiên, kết quả bước đầu cho thấy hướng kết hợp mô hình ngôn ngữ lớn với truy xuất điều luật có tiềm năng ứng dụng trong các bài toán hỏi đáp pháp lý tiếng Việt

TP. Hồ Chí Minh, ngày 7 tháng 5 năm 2026

Tác giả

(Ký tên và ghi rõ họ tên)

Khôi

Đào Minh Khôi

Tín

Hà Huy Tín

Vinh

Bùi Quang Vinh

CÔNG TRÌNH ĐƯỢC HOÀN THÀNH TẠI TRƯỜNG ĐẠI HỌC TÔN ĐỨC THẮNG

Tôi xin cam đoan đây là công trình nghiên cứu của riêng tôi và được sự hướng dẫn khoa học của Pgs. Ts. Lê Anh Cường. Các nội dung nghiên cứu, kết quả trong đề tài này là trung thực và chưa công bố dưới bất kỳ hình thức nào trước đây. Những số liệu trong các bảng biểu phục vụ cho việc phân tích, nhận xét, đánh giá được chính tác giả thu thập từ các nguồn khác nhau có ghi rõ trong phần tài liệu tham khảo.

Ngoài ra, trong Dự án còn sử dụng một số nhận xét, đánh giá cũng như số liệu của các tác giả khác, cơ quan tổ chức khác đều có trích dẫn và chú thích nguồn gốc.

Nếu phát hiện có bất kỳ sự gian lận nào tôi xin hoàn toàn chịu trách nhiệm về nội dung Dự án của mình. Trường Đại học Tôn Đức Thắng không liên quan đến những vi phạm tác quyền, bản quyền do tôi gây ra trong quá trình thực hiện (nếu có).

TP. Hồ Chí Minh, ngày 7 tháng 5 năm 2026

Tác giả

(Ký tên và ghi rõ họ tên)

Khôi

Đào Minh Khôi

Tín

Hà Huy Tín

Vinh

Bùi Quang Vinh

HỆ THỐNG HỎI ĐÁP PHÁP LUẬT - LUẬT DÂN SỰ 2015

TÓM TẮT

Đề tài xây dựng một hệ thống hỏi đáp tự động cho Bộ luật Dân sự 2015 (BLDS2015), hướng tới khả năng tiếp nhận câu hỏi tiếng Việt, truy xuất điều khoản liên quan và sinh câu trả lời có căn cứ pháp lý. Hệ thống được thiết kế theo hai hướng bổ sung cho nhau: Retrieval-Augmented Generation (RAG) để đưa điều luật thực tế vào ngữ cảnh suy luận và fine-tuning Qwen2.5-3B-Instruct bằng QLoRA để mô hình học cách trả lời theo văn phong, cấu trúc và yêu cầu trích dẫn của bộ dữ liệu hỏi đáp pháp luật.

Dữ liệu thực nghiệm gồm 3.566 mẫu hỏi đáp, chia thành 2.496 mẫu huấn luyện, 534 mẫu validation và 536 mẫu test. Kho luật được chunk theo đơn vị điều luật, tạo 711 chunks từ 689 điều, kèm metadata phân cấp theo Phần - Chương - Mục - Điều. Về truy xuất, hệ thống dùng embedding tiếng Việt, FAISS IndexFlatIP, cơ chế MemPalace Metadata Scoping để thu hẹp phạm vi tìm kiếm, và Cross-Encoder Reranking để xếp hạng lại các điều khoản ứng viên. Về mô hình sinh, hệ thống dùng Qwen2.5-3B-Instruct với LoRA/QLoRA 4-bit, huấn luyện 3 epoch trên GPU Tesla T4.

Kết quả đánh giá bốn cấu hình cho thấy fine-tuning giúp cải thiện rõ rệt chất lượng sinh câu trả lời. Cấu hình fine-tuned không RAG đạt BLEU-4 = 0,462, ROUGE-L = 0,433 và BERTScore-F1 = 0,759, cao nhất trong các cấu hình được đo trên biểu đồ tổng hợp. Cấu hình fine-tuned + RAG có BERTScore-F1 = 0,729 và latency trung bình 21,07 giây, cho thấy truy xuất vẫn có vai trò trong việc cung cấp căn cứ điều luật, nhưng cần tối ưu thêm về chọn ngữ cảnh, prompt và reranking để tránh nhiễu.

Từ khóa: Bộ luật Dân sự 2015, hỏi đáp pháp luật, RAG, FAISS, BM25, Qwen2.5-3B-Instruct, QLoRA, LoRA, BERTScore.

MỤC LỤC

DANH MỤC CÁC CHỮ VIẾT TẮT.....	vi
CHƯƠNG 1. MỞ ĐẦU VÀ TỔNG QUAN ĐỀ TÀI.....	1
1.1 Lý do chọn đề tài	1
1.2 Mục tiêu thực hiện đề tài	1
1.3 Phạm vi và đối tượng nghiên cứu.....	2
1.4 Dữ liệu đầu vào và phân chia tập dữ liệu.	2
CHƯƠNG 2. CƠ SỞ LÝ THUYẾT.....	4
2.1 Retrieval-Augmented Generation	4
2.2 Chunking văn bản pháp lý	4
2.3 Embedding và tìm kiếm vector	4
2.4 BM25 và hybrid retrieval.....	5
2.5 Cross-Encoder Reranking	5
2.6 Qwen2.5-3B-Instruct và QLoRA	6
CHƯƠNG 3. PHƯƠNG PHÁP VÀ MÔ HÌNH ĐỀ XUẤT	7
3.1 Tổng quan kiến trúc hệ thống.....	7
3.2 MemPalace Metadata Scoping.....	7
3.3 Thiết kế index và retriever	8
3.4 Prompt Engineering	8
3.5 Cấu hình fine-tuning.....	9
3.6 Các cấu hình thực nghiệm.....	10
CHƯƠNG 4. THỰC NGHIỆM VÀ ĐÁNH GIÁ	11
4.1 Môi trường và quy trình thực nghiệm	11

4.2 Phân tích dữ liệu thật	12
4.3 Đường cong huấn luyện	12
4.4 Chỉ số đánh giá	13
4.5 Kết quả so sánh bốn cấu hình.....	13
4.6 Phân tích ưu điểm và hạn chế từng cấu hình	15
4.7 Phân tích nguyên nhân cấu hình Fine-tuned + RAG chưa vượt Fine-tuned	16
4.8 Đánh giá định tính qua ví dụ	16
CHƯƠNG 5. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN	17
5.1 Kết luận.....	17
5.2 Hướng phát triển.....	17
5.3 Hạn chế	18
5.4 Hướng phát triển.....	18
TÀI LIỆU THAM KHẢO	20

DANH MỤC CÁC CHỮ VIẾT TẮT

BLDS2015	Bộ luật Dân sự 2015
RAG	Retrieval-Augmented Generation - sinh câu trả lời có bổ sung truy xuất
QLoRA	Low-Rank Adaptation - học ma trận cập nhật hạng thấp
LoRA	Natural Language Processing
FAISS	Facebook AI Similarity Search - thư viện tìm kiếm vector
BM25	Best Match 25 - thuật toán truy xuất sparse dựa trên TF-IDF
SBERT	Sentence-BERT - encoder tạo embedding câu
BERTScore	Chỉ số đánh giá dựa trên embedding ngữ cảnh
ChatML	Định dạng hội thoại system/user/assistant dùng cho Qwen

CHƯƠNG 1. MỞ ĐẦU VÀ TỔNG QUAN ĐỀ TÀI

1.1 Lý do chọn đề tài

Trong lĩnh vực pháp luật, câu trả lời sai hoặc thiếu căn cứ có thể dẫn đến hiểu nhầm nghiêm trọng. Các mô hình ngôn ngữ lớn có khả năng diễn đạt tốt, nhưng thường gặp hiện tượng hallucination, đặc biệt khi yêu cầu trích dẫn điều luật cụ thể. Đối với BLDS2015, người dùng không chỉ cần một câu trả lời tự nhiên bằng tiếng Việt mà còn cần biết câu trả lời dựa trên Điều nào, Chương nào và nội dung pháp lý nào. Vì vậy, hệ thống hỏi đáp pháp luật cần kết hợp khả năng hiểu ngôn ngữ với cơ chế truy xuất văn bản pháp luật chính xác.

Đề tài lựa chọn BLDS2015 vì đây là văn bản nền tảng điều chỉnh nhiều quan hệ dân sự phổ biến như cá nhân, pháp nhân, tài sản, giao dịch dân sự, hợp đồng, nghĩa vụ, thừa kế và bồi thường thiệt hại. Tập văn bản có cấu trúc phân cấp rõ ràng, phù hợp để thiết kế metadata theo Phần - Chương - Mục - Điều, từ đó phục vụ truy xuất có kiểm soát thay vì tìm kiếm toàn văn đơn thuần.

1.2 Mục tiêu thực hiện đề tài

- Xây dựng pipeline hỏi đáp tiếng Việt cho BLDS2015, trả lời ngắn gọn và có trích dẫn điều luật.
- Thiết kế chiến lược chunking giữ nguyên văn điều luật để tránh thay đổi nghĩa pháp lý.
- Xây dựng cơ chế RAG gồm scoping metadata, dense retrieval, tùy chọn BM25/hybrid search và reranking.
- Fine-tune Qwen2.5-3B-Instruct bằng QLoRA để mô hình học định dạng trả lời pháp lý.
- So sánh bốn cấu hình: Base, Base + RAG, Fine-tuned, Fine-tuned + RAG bằng BLEU-4, ROUGE-L, BERTScore-F1 và latency.
- Phân tích kết quả, chỉ ra nguyên nhân cải thiện hoặc suy giảm và đề xuất hướng phát triển.

1.3 Phạm vi và đối tượng nghiên cứu.

Đối tượng nghiên cứu là hệ thống hỏi đáp tự động trên phạm vi BLDS2015. Hệ thống không nhằm thay thế chuyên gia pháp lý mà đóng vai trò trợ lý tìm kiếm, tóm tắt và giải thích điều luật. Phạm vi dữ liệu của báo cáo dựa trên bộ chunks luật, dataset hỏi đáp đã chuẩn hóa và các kết quả thực nghiệm đã có trong notebook. Các câu hỏi chủ yếu thuộc nhóm quy định chung, quyền sở hữu, hợp đồng, giao dịch dân sự, thừa kế, quyền nhân thân, pháp nhân, bồi thường thiệt hại và pháp luật áp dụng.

1.4 Dữ liệu đầu vào và phân chia tập dữ liệu.

Dataset hỏi đáp được chuẩn hóa theo ChatML để phù hợp với Qwen2.5-3B-Instruct. Mỗi mẫu chứa system prompt, câu hỏi của người dùng và câu trả lời chuẩn của assistant. System prompt yêu cầu mô hình đóng vai trợ lý pháp lý chuyên về BLDS2015, trả lời chính xác, ngắn gọn dựa trên điều khoản cụ thể, và nếu câu hỏi đúng/sai thì phải kết luận rõ ràng trước khi giải thích.

Tập dữ liệu	Số mẫu	Tỷ lệ xấp xỉ
Train	2.496	70,0%
Validation	534	15,0%
Test	536	15,0%
Tổng cộng	3.566	100%

Tập train có phân bố category không đồng đều. Nhóm quy định chung, tài sản/sở hữu, hợp đồng và giao dịch dân sự chiếm tỷ trọng lớn, phản ánh các nhóm nội dung xuất hiện nhiều trong BLDS2015 cũng như trong bộ câu hỏi huấn luyện. Sự mất cân bằng này cần được lưu ý khi đánh giá, vì mô hình có thể học tốt hơn ở những nhóm nhiều mẫu và yếu hơn ở nhóm ít mẫu như giám hộ hoặc đại diện.

Category	Số mẫu train	Nhận xét
quy_dinh_chung	547	Nhóm lớn nhất; bao phủ nguyên tắc và quy định nền tảng.

tai_san_so_huu	436	Nhiều câu hỏi về tài sản, sở hữu, chiếm hữu, sử dụng, định đoạt.
hop_dong	426	Nhóm quan trọng cho nghĩa vụ và hợp đồng phổ biến.
giao_dich_dan_su	297	Tập trung điều kiện có hiệu lực, vô hiệu, hình thức giao dịch.
thua_ke	251	Bao gồm di chúc, di sản, hàng thừa kế, thừa kế theo pháp luật.
quyen_nhan_than	218	Các câu hỏi về quyền cá nhân và quyền nhân thân.
phap_nhan	130	Nội dung về thành lập, đại diện và trách nhiệm của pháp nhân.
boi_thuong_thiet_hai	77	Nhóm ít hơn nhưng có tính thực tiễn cao.
phap_luat_ap_dung	74	Liên quan xung đột pháp luật và áp dụng pháp luật.
nang_luc_hanh_vi	27	Ít mẫu; cần tăng dữ liệu để ổn định hơn.
dai_dien	12	Rất ít mẫu; dễ gây thiếu bao phủ.
giam_ho	1	Gần như không đủ để mô hình học riêng category này.

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT

2.1 Retrieval-Augmented Generation

Retrieval-Augmented Generation là cách kết hợp một mô hình sinh ngôn ngữ với thành phần truy xuất thông tin. Thay vì yêu cầu LLM tự nhớ toàn bộ nội dung luật, hệ thống trước hết tìm các điều khoản liên quan rồi đưa chúng vào prompt làm ngữ cảnh. Điều này đặc biệt phù hợp với pháp luật vì nội dung cần căn cứ chính xác, có thể thay đổi theo văn bản mới, và thường đòi hỏi trích dẫn số Điều.

Trong đề tài, RAG gồm các bước: nhận câu hỏi, xác định phạm vi Chương liên quan, truy xuất top-k điều khoản bằng vector search/hybrid search, định dạng ngữ cảnh pháp lý, gọi LLM sinh câu trả lời, và trả về câu trả lời kèm trích dẫn. Cơ chế này giúp giảm hallucination, nhưng chất lượng phụ thuộc mạnh vào bước chọn ngữ cảnh. Nếu truy xuất nhầm hoặc đưa quá nhiều đoạn không liên quan, LLM có thể bị nhiễu và điểm BLEU/ROUGE giảm.

2.2 Chunking văn bản pháp lý

Trong văn bản pháp luật, đơn vị ý nghĩa tự nhiên là Điều luật. Vì vậy, chiến lược chunking của đề tài ưu tiên mỗi chunk tương ứng một Điều. Với một số Điều dài hoặc có cấu trúc phức tạp, hệ thống có thể chia thêm theo khoản, tạo ra tổng cộng 711 chunks từ 689 Điều. Việc giữ nguyên văn bản gốc theo nguyên tắc verbatim là quan trọng, vì paraphrase có thể làm thay đổi nghĩa pháp lý hoặc làm mất dấu hiệu trích dẫn.

Mỗi chunk được gắn metadata gồm số Phần, tên Phần, số Chương, tên Chương, số Mục, tên Mục, số Điều, tên Điều, loại chunk và số token. Metadata vừa hỗ trợ truy xuất theo phạm vi vừa giúp mô hình trả lời có căn cứ pháp lý rõ ràng. Ví dụ, citation đầy đủ có thể gồm: Điều, tên điều, Mục, Chương, Phần và tên văn bản luật.

2.3 Embedding và tìm kiếm vector

Embedding biến câu hỏi và điều luật thành vector trong không gian ngữ nghĩa. Hệ thống sử dụng Sentence Transformer, cụ thể trong notebook là keepitreal/vietnamese-sbert với dimension 768. Vector được normalize để cosine similarity tương đương inner product. Nhờ đó, FAISS IndexFlatIP có thể thực hiện tìm kiếm nearest neighbor bằng tích vô hướng mà vẫn phản ánh độ gần ngữ nghĩa giữa câu hỏi và chunk luật.

Trong cấu trúc index, hệ thống có một global index chứa 711 vectors và các sub-index theo Chương. Khi scoping xác định được một số Chương liên quan, truy xuất sẽ chạy trên sub-index thay vì toàn bộ corpus. Nếu kết quả scoped quá ít, hệ thống dùng global index làm fallback. Thiết kế hai tầng này cân bằng giữa precision và recall.

2.4 BM25 và hybrid retrieval

BM25 là thuật toán sparse retrieval dựa trên tần suất từ khóa và nghịch đảo tần suất tài liệu. Trong bối cảnh pháp luật, BM25 mạnh khi câu hỏi chứa từ khóa chính xác như số Điều, tên chế định, tên hợp đồng hoặc thuật ngữ pháp lý cố định. Dense retrieval lại mạnh khi người dùng diễn đạt bằng paraphrase hoặc ngôn ngữ đời thường. Vì vậy, hướng hybrid kết hợp BM25 và dense vector giúp tận dụng cả khớp từ khóa lẫn khớp ngữ nghĩa.

2.5 Cross-Encoder Reranking

Bi-encoder như SBERT encode câu hỏi và tài liệu độc lập, vì vậy tốc độ nhanh và phù hợp tìm kiếm trong tập lớn, nhưng không mô hình hóa đầy đủ tương tác giữa từng token của câu hỏi và từng token của điều luật. Cross-encoder nhận cặp [query; document] và xử lý chung, chậm hơn nhưng chính xác hơn trong xếp hạng lại. Hệ thống dùng BGE-Reranker-V2-M3 để rerank các chunk lấy thô từ FAISS, từ fetch_k = 20 xuống top_k = 5.

2.6 Qwen2.5-3B-Instruct và QLoRA

Qwen2.5-3B-Instruct là mô hình decoder-only theo phong cách GPT, hỗ trợ instruction-following. Kiến trúc sử dụng các thành phần hiện đại như Grouped Query Attention, SwiGLU, RoPE và RMSNorm. Trong đề tài, mô hình được sử dụng làm base LLM cho cả cấu hình không fine-tune và cấu hình gắn adapter LoRA sau fine-tuning.


QLoRA kết hợp lượng tử hóa 4-bit với LoRA. Trọng số nền được nén bằng NF4, có double quantization và tính toán tạm thời ở bfloat16. Thay vì cập nhật toàn bộ tham số mô hình, LoRA chỉ học các ma trận hạng thấp A và B, với cập nhật delta $W = B \times A$. Cách này giảm đáng kể VRAM, phù hợp môi trường GPU Tesla T4 15,6 GB trong notebook.

CHƯƠNG 3. PHƯƠNG PHÁP VÀ MÔ HÌNH ĐỀ XUẤT

3.1 Tổng quan kiến trúc hệ thống

Pipeline đề xuất gồm sáu giai đoạn tuần tự: Query, Scope, Retrieve, Context, LLM và Answer. Người dùng nhập câu hỏi tiếng Việt. MemPalace Metadata Scoper phân loại câu hỏi vào một số Chương liên quan. Bộ retriever tìm top-k điều khoản trong phạm vi đã scope bằng vector search và có thể kết hợp sparse retrieval. Reranker xếp hạng lại ứng viên. Context được định dạng thành prompt pháp lý. Cuối cùng, Qwen2.5-3B-Instruct hoặc mô hình fine-tuned sinh câu trả lời có căn cứ.

Pipeline 6 giai đoạn tuần tự (BLDS2015-RAG-QA):



RAG kết hợp truy xuất thông tin (Retrieval) với sinh ngôn ngữ (Generation) — bổ sung kiến thức pháp lý thực tế mà LLM không có trong training data.

4 cấu hình thực nghiệm: Base | Base+RAG | Fine-tuned | Fine-tuned+RAG

Figure 3.1: Kiến trúc tổng thể pipeline RAG-QA cho BLDS2015

3.2 MemPalace Metadata Scoping

Scoping là điểm khác biệt quan trọng của hệ thống. Thay vì tìm kiếm trên toàn bộ 711 chunks, hệ thống trước hết chọn 1-3 Chương có khả năng liên quan nhất. Ý tưởng lấy cảm hứng từ Memory Palace: mỗi Chương được xem như một không gian có các từ khóa đặc trưng, ví dụ Chương hợp đồng có “hợp đồng”, “ký kết”, “vi phạm”, “bồi thường”; Chương thừa kế có “thừa kế”, “di chúc”, “di sản”, “người thừa kế”; Chương cá nhân có “cá nhân”, “năng lực”, “hành vi”, “mất tích”.

Điểm tổng gồm điểm keyword và điểm semantic giữa embedding câu hỏi với embedding tên Chương. Trọng số 2,0 dành cho semantic similarity giúp hệ thống vẫn

khái quát được khi câu hỏi không chứa đúng từ khóa. Khi scoping tốt, không gian tìm kiếm giảm hơn 85%, từ toàn bộ kho xuống khoảng 50-150 chunks, đồng thời tăng xác suất top-k chứa điều luật đúng.

3.3 Thiết kế index và retriever

Thành phần	Cấu hình trong đề tài	Vai trò
Chunking	711 chunks từ 689 Điều; 676 chunks điều nguyên, 35 chunks khoản	Đảm bảo đơn vị pháp lý độc lập và giữ nguyên văn bản.
Metadata	Phần - Chương - Mục - Điều	Hỗ trợ scoping, citation và kiểm soát phạm vi.
Embedding	keepitreal/vietnamese-sbert, dim = 768, normalize_embeddings = True	Biểu diễn ngữ nghĩa câu hỏi và điều luật.
FAISS	IndexFlatIP, global index + sub-index theo Chương	Tìm nearest neighbor bằng inner product/cosine.
Scoping	Top-3 Chương theo keyword + semantic similarity	Giảm không gian tìm kiếm và tăng precision.
Reranking	BGE-Reranker-V2-M3, fetch_k = 20, top_k = 5	Xếp hạng lại theo tương tác query-document.
Context	Top-k chunks + citation đầy đủ	Cung cấp căn cứ pháp lý cho LLM.

3.4 Prompt Engineering

Prompt RAG gồm ba phần: ngữ cảnh pháp lý, câu hỏi và yêu cầu trả lời. Ngữ cảnh chứa top-k chunks kèm citation đầy đủ. Câu hỏi giữ nguyên tiếng Việt của người dùng. Yêu cầu trả lời bắt buộc mô hình dựa vào các điều luật đã cho, trả lời câu hỏi và trích dẫn rõ ràng số Điều làm căn cứ pháp lý.

[NGŨ CẢNH PHÁP LÝ]

{context}

[CÂU HỎI]

{question}

[YÊU CẦU TRẢ LỜI]

Dựa vào các điều luật trên, hãy trả lời câu hỏi và trích dẫn rõ ràng số Điều làm căn cứ pháp lý.

Một điểm quan trọng là distribution matching: system prompt khi inference phải khớp với system prompt trong dataset fine-tuning. Nếu prompt thay đổi quá nhiều, phân phối đầu vào của mô hình khi suy luận khác với lúc huấn luyện, có thể làm giảm chất lượng câu trả lời.

3.5 Cấu hình fine-tuning

Fine-tuning sử dụng completion-only loss, nghĩa là loss chỉ tính trên phần assistant response, còn phần system và user được mask bằng nhãn -100. Cách này giúp mô hình tập trung học cách trả lời, không học lại prompt đầu vào. Notebook đặt SKIP_FINETUNING = True khi đã có model fine-tuned, nhưng vẫn lưu đầy đủ cấu hình huấn luyện để tái lập.

Nhóm cấu hình	Giá trị	Ý nghĩa
Base model	Qwen/Qwen2.5-3B-Instruct	Mô hình nền instruction-following 3B.
Quantization	NF4 4-bit, double quantization, bf16 compute	Giảm VRAM nhưng vẫn giữ chất lượng tính toán.
LoRA rank/alpha/dropout	r = 16, alpha = 32, dropout = 0,05	Kiểm soát năng lực adapter và regularization.

Target modules	q_proj, k_proj, v_proj, o_proj, gate_proj, up_proj, down_proj	Fine-tune attention và MLP projection.
Epochs	3	Huấn luyện qua 3 vòng dữ liệu.
Batch	per_device_train_batch_size = 1, gradient_accumulation_steps = 8	Effective batch size xấp xỉ 8 để phù hợp T4.
Learning rate	2e-4	Tốc độ học cho LoRA adapters.
Scheduler	Cosine, warmup_ratio = 0,05	Ổn định giai đoạn đầu và giảm dần LR.
Optimizer	paged_adamw_8bit	Giảm bộ nhớ optimizer states.
MAX_SEQ_LEN	2048	Giới hạn độ dài chuỗi huấn luyện.

3.6 Các cấu hình thực nghiệm

Để tách riêng đóng góp của RAG và fine-tuning, hệ thống được đánh giá theo ma trận 2x2. Trục thứ nhất là mô hình gốc hoặc fine-tuned; trục thứ hai là có hoặc không có RAG. Bốn cấu hình này cho phép quan sát liệu cải thiện đến từ khả năng sinh của mô hình, từ truy xuất ngữ cảnh, hay từ sự kết hợp của cả hai.

Ký hiệu	Mô hình	RAG	Mục đích so sánh
A	Base Qwen2.5-3B-Instruct	Không	Đường cơ sở, đo khả năng trả lời trực tiếp của model gốc.
B	Base Qwen2.5-3B-Instruct	Có	Đo tác động của truy xuất khi chưa fine-tune.

C	Fine-tuned Qwen2.5-3B- Instruct + LoRA	Không	Đo tác động của fine-tuning riêng lẻ.
D	Fine-tuned Qwen2.5-3B- Instruct + LoRA	Có	Đo tác động của kết hợp fine- tuning và RAG.

CHƯƠNG 4. THỰC NGHIỆM VÀ ĐÁNH GIÁ

4.1 Môi trường và quy trình thực nghiệm

Notebook được chạy trên môi trường Colab với GPU Tesla T4, VRAM 15,6 GB. Các thư viện chính gồm PyTorch, Transformers, Accelerate, PEFT, BitsAndBytes, TRL, Datasets, Sentence-Transformers, FAISS, Evaluate, BERTScore, ROUGE-Score, NLTK, Pandas, NumPy, Matplotlib, Seaborn, Underthesea và Pyvi. Kết quả training history, biểu đồ loss, metrics summary và biểu đồ so sánh được lưu trong thư mục outputs của dự án

4.2 Phân tích dữ liệu thật

Kho BLDS2015 được parse thành 721 records và chuyển thành 711 LegalChunks. Trong đó có 676 chunks loại `diu_nguyen` và 35 chunks loại `khoan`. Hệ thống tạo index theo 6 Phần, 28 Chương có dữ liệu và 676 Điều nguyên. Biểu đồ phân tích dữ liệu cho thấy phần lớn chunks có độ dài ngắn đến trung bình; mean token count xấp xỉ 180 token theo biểu đồ. Số Điều phân bố không đều theo Chương, trong đó Chương “Một số hợp đồng thông dụng” và nhóm thừa kế có số lượng điều lớn, dẫn đến nhu cầu scoping theo Chương để tránh tìm kiếm dàn trải.




Figure 4.1 Phân tích dữ liệu BLDS2015 theo độ dài chunk và số điều theo chương.

4.3 Đường cong huấn luyện

Đường cong loss cho thấy train loss giảm mạnh từ khoảng 1,6 ở giai đoạn đầu xuống dưới 0,2 ở giai đoạn sau, thể hiện mô hình học được định dạng và nội dung trả lời từ dataset. Train loss có các dao động dạng răng cưa, có thể đến từ độ dài mẫu

khác nhau, gradient accumulation và lịch học cosine. Eval loss giảm từ khoảng 0,37 xuống 0,26 sau các epoch đầu, sau đó gần như đi ngang. Điều này cho thấy mô hình đã đạt vùng hội tụ ban đầu; nếu tiếp tục huấn luyện, cần theo dõi overfitting và có thể thử giảm learning rate hoặc tăng dữ liệu validation theo nhóm category.




Figure 4.2 : Training loss và validation loss của Qwen2.5-3B-Instruct QLoRA

4.4 Chỉ số đánh giá

Báo cáo sử dụng ba chỉ số chất lượng và một chỉ số hiệu năng. BLEU-4 đo độ trùng khớp n-gram từ 1 đến 4-gram, nhạy với cách diễn đạt. ROUGE-L đo Longest Common Subsequence, chấp nhận một phần thay đổi thứ tự và paraphrase. BERTScore-F1 dựa trên embedding ngữ cảnh, phù hợp hơn với tiếng Việt vì có thể nhận ra tương đồng ngữ nghĩa dù câu trả lời không trùng từng từ. Latency đo thời gian sinh câu trả lời trung bình, phản ánh chi phí suy luận.

4.5 Kết quả so sánh bốn cấu hình




Figure 4.3 So sánh bốn cấu hình theo BLEU-4, ROUGE-L, BERTScore-F1 và latency.

Cấu hình	BLEU-4	ROUGE-L	BERTScore-F1	Latency (s)	Nhận xét chính
A: Base No RAG	0,372	0,347	0,705	15,840	Nhanh nhất; chất lượng nền tảng chấp nhận được nhưng thiếu grounding.
B: Base + RAG	0,428	0,359	0,699	25,300	BLEU/ROUGE tăng nhẹ nhờ context; BERTScore giảm nhẹ; độ trễ cao nhất.
C: Fine-tuned No RAG	0,462	0,433	0,759	24,290	Tốt nhất theo ba metric chất lượng trong biểu đồ; chứng tỏ fine-tuning hiệu quả.
D: Fine-tuned + RAG	0,223	0,348	0,729	21,070	Có grounding nhưng BLEU giảm mạnh; cần tối ưu retrieval/prompt

					để giảm nhiễu context.
--	--	--	--	--	------------------------

Kết quả cần được diễn giải cẩn trọng. Fine-tuning riêng lẻ (C) đạt điểm cao nhất ở BLEU-4, ROUGE-L và BERTScore-F1, cho thấy adapter LoRA đã học tốt cách sinh câu trả lời theo phân phối của dataset. Base + RAG (B) cải thiện BLEU-4 và ROUGE-L so với Base (A), nhưng BERTScore-F1 giảm nhẹ, có thể do context đưa vào làm câu trả lời dài hoặc lệch so với reference. Fine-tuned + RAG (D) có BERTScore-F1 cao hơn Base và Base + RAG, nhưng BLEU-4 thấp; điều này có thể xảy ra nếu mô hình đưa thêm căn cứ, trích dẫn hoặc diễn giải khác reference, làm giảm trùng khớp n-gram.

4.6 Phân tích ưu điểm và hạn chế từng cấu hình

Cấu hình	Ưu điểm	Hạn chế	Khi nên dùng
A	Độ trễ thấp nhất; triển khai đơn giản; không cần index luật.	Dễ hallucination; khó đảm bảo trích dẫn điều luật đúng; phụ thuộc kiến thức đã học.	Demo nhanh, baseline hoặc câu hỏi chung không cần căn cứ chi tiết.
B	Có ngữ cảnh pháp lý; cải thiện lexical metrics so với base; dễ cập nhật luật bằng index.	Tăng latency; context có thể nhiễu nếu retrieval chưa tốt; mô hình chưa học sâu văn phong pháp lý.	Khi cần cập nhật tri thức pháp luật mà chưa có fine-tuned model.
C	Chất lượng sinh tốt nhất theo biểu đồ; văn phong và định dạng trả lời ổn định.	Không kiểm chứng điều luật tại inference; tri thức có thể lỗi thời nếu luật thay đổi; khó đảm bảo trích dẫn luôn đúng.	Khi dataset ổn định và yêu cầu độ trễ/chất lượng câu trả lời cân bằng.
D	Kết hợp học định dạng với	Trong kết quả hiện tại chưa vượt C;	Phiên bản mục tiêu cho triển khai

	grounding; có thể dẫn nguồn điều luật tại runtime.	cần tối ưu chọn context và prompt để tránh nhiễu.	thực tế sau khi tối ưu RAG.
--	--	---	-----------------------------

4.7 Phân tích nguyên nhân cấu hình Fine-tuned + RAG chưa vượt Fine-tuned

- Reference answers trong dataset có thể ngắn gọn, trong khi RAG khiến mô hình trả lời dài hơn hoặc trích dẫn nhiều hơn, làm BLEU/ROUGE giảm.
- Top-k context có thể chứa điều liên quan nhưng không hoàn toàn khớp câu hỏi; mô hình fine-tuned bị kéo theo ngữ cảnh nhiễu.
- System prompt và RAG prompt có thể tạo distribution shift so với prompt fine-tuning nếu cấu trúc hoặc độ dài khác đáng kể.
- BGE reranker chọn top-5 theo relevance chung, nhưng pháp luật đòi hỏi đúng điều căn cứ; relevance ngữ nghĩa chưa chắc tương ứng với legal correctness.
- Đánh giá 50 câu mẫu có thể chưa ổn định; cần báo cáo thêm confidence interval hoặc đánh giá toàn bộ test set cho cả bốn cấu hình.

4.8 Đánh giá định tính qua ví dụ

Một ví dụ trong slide là câu hỏi: “Nếu bên cho thuê không thực hiện đúng nghĩa vụ liên quan đến hành vi lạm dụng quyền dân sự, hậu quả là gì?”. Câu trả lời fine-tuning nêu rằng cá nhân, pháp nhân không tuân thủ quy định có thể không được bảo vệ một phần hoặc toàn bộ quyền, phải bồi thường nếu gây thiệt hại và có thể chịu chế tài khác theo luật. Ví dụ này cho thấy mô hình đã học được phong cách trả lời dựa trên quy định pháp luật và biết diễn đạt hậu quả pháp lý theo cấu trúc điều khoản.

Tuy nhiên, ví dụ cũng chỉ ra yêu cầu quan trọng: hệ thống cần trích dẫn rõ số Điều. Nếu câu trả lời có nội dung đúng nhưng thiếu số Điều hoặc trích dẫn sai, trong bối cảnh pháp lý vẫn chưa đạt yêu cầu. Vì vậy, ngoài BLEU/ROUGE/BERTScore, các phiên bản sau nên bổ sung chỉ số citation accuracy, recall@k theo điều luật đúng, và human evaluation bởi người có kiến thức pháp luật.

CHƯƠNG 5. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

5.1 Kết luận

Báo cáo đã trình bày quá trình xây dựng hệ thống hỏi đáp BLDS2015 dựa trên RAG và QLoRA fine-tuning. Về dữ liệu, hệ thống chunk văn bản luật theo điều khoản, giữ nguyên văn bản gốc và gắn metadata phân cấp. Về truy xuất, hệ thống kết hợp embedding tiếng Việt, FAISS multi-index, MemPalace Metadata Scoping và Cross-Encoder Reranking để lấy top-k căn cứ pháp lý. Về sinh câu trả lời, hệ thống dùng Qwen2.5-3B-Instruct với ChatML prompt và LoRA adapters được huấn luyện bằng completion-only loss.

Kết quả định lượng cho thấy fine-tuning mang lại cải thiện rõ nhất trong thiết lập hiện tại. Cấu hình Fine-tuned No RAG đạt điểm cao nhất ở BLEU-4, ROUGE-L và BERTScore-F1. RAG giúp đưa căn cứ luật vào prompt, nhưng cấu hình Fine-tuned + RAG chưa vượt Fine-tuned No RAG trong biểu đồ, đặc biệt BLEU-4 giảm mạnh. Điều này không phủ nhận vai trò của RAG mà cho thấy cần tối ưu retrieval, prompt và tiêu chí đánh giá phù hợp hơn với bài toán pháp lý/

5.2 Hướng phát triển

Thiết kế pipeline QA pháp lý tiếng Việt có căn cứ điều luật cho BLDS2015.

- Xây dựng cấu trúc LegalChunk và citation đầy đủ theo Điều - Mục - Chương - Phần.
- Áp dụng scoping metadata để giảm không gian tìm kiếm và tăng tính phù hợp của retrieval.
- Kết hợp bi-encoder retrieval và cross-encoder reranking trong pipeline RAG.
- Fine-tune Qwen2.5-3B-Instruct bằng QLoRA trên GPU T4, giảm chi phí tài nguyên.
- So sánh bốn cấu hình để tách riêng tác động của RAG và fine-tuning.

5.3 Hạn chế

- Dataset chưa cân bằng giữa các category; một số nhóm như giám hộ, đại diện, năng lực hành vi có rất ít mẫu.
- Đánh giá bốn cấu hình mới thể hiện trên 50 câu mẫu trong biểu đồ; cần mở rộng toàn bộ test set cho so sánh ổn định hơn.
- Chưa có metric riêng cho độ chính xác trích dẫn điều luật, trong khi đây là yêu cầu cốt lõi của hệ thống pháp lý.
- RAG làm tăng độ trễ và có thể đưa ngữ cảnh nhiễu vào prompt nếu retrieval/reranking chưa tối ưu.
- Chưa triển khai kiểm chứng câu trả lời bằng rule-based citation checker hoặc verifier độc lập.
- Demo Gradio mới ở mức thử nghiệm, chưa có cơ chế logging, phản hồi người dùng hoặc kiểm soát nguồn.

5.4 Hướng phát triển

- Bổ sung dữ liệu cho các category ít mẫu và tạo thêm câu hỏi khó có nhiều điều luật liên quan.
- Đánh giá citation accuracy, article recall@k, exact legal reference match và faithfulness bên cạnh BLEU/ROUGE/BERTScore.
- Tối ưu RAG bằng hybrid score calibration, query rewriting, lọc context theo số Điều và reranking có huấn luyện trên dữ liệu pháp lý.
- Thử nghiệm các chiến lược prompt như yêu cầu trả lời ngắn, chỉ dùng điều luật liên quan nhất hoặc buộc liệt kê căn cứ trước khi giải thích.
- So sánh thêm multilingual-e5-large, Vietnamese SBERT và các embedding model mới cho retrieval tiếng Việt.
- Triển khai verifier hậu xử lý để kiểm tra số Điều được trích dẫn có nằm trong context và có phù hợp với câu hỏi không.
- Tối ưu latency bằng cache embedding, quantization inference, giảm top_k hoặc dùng reranker nhẹ hơn trong production.

- Mở rộng sang các văn bản luật khác và xây dựng pipeline cập nhật khi văn bản pháp luật thay đổi.

TÀI LIỆU THAM KHẢO

Bộ luật Dân sự năm 2015, Luật số 91/2015/QH13

Vaswani, A. et al. Attention Is All You Need.

Reimers, N., & Gurevych, I. Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks.

Dettmers, T. et al. QLoRA: Efficient Finetuning of Quantized LLMs.

Johnson, J., Douze, M., & Jegou, H. Billion-scale similarity search with GPUs.

Robertson, S., & Zaragoza, H. The Probabilistic Relevance Framework: BM25 and beyond.

Qwen Team. Qwen2.5 model documentation and technical materials.

BAAI. BGE reranker model documentation.